

BÁO CÁO TỔNG HỢP PIPELINE TIỀN XỬ LÝ TỐI ƯU

ĐỒ ÁN NHẬN DIỆN BÌNH LUẬN CÓ TÍNH XÚC PHẠM (VIHSD)

1. Tổng quan & Bối cảnh Đề án

Bài toán nhận diện ngôn từ thù địch và xúc phạm trên mạng xã hội tiếng Việt đối mặt với thách thức rất lớn do bản chất phi chuẩn của ngôn ngữ mạng (Teencode, từ lóng, biểu tượng cảm xúc, từ viết tắt và biến thể ký tự). Trong bài báo khoa học gốc của bộ dữ liệu **ViHSD (Vietnamese Hate Speech Detection)**, mô hình đạt kết quả tốt nhất là m-BERT cased với chỉ số F1-macro là **62.69%**.

Tuy nhiên, phân tích lỗi cho thấy bộ tách từ (tokenizer) nguyên bản thường bị sụp đổ hoặc mất mát ngữ nghĩa nghiêm trọng khi gặp phải các cấu trúc teencode biến thể nặng như "dell", "lol", "cc", hay các ký tự biểu đạt cảm xúc (Emoji) bị loại bỏ hoàn toàn. Mục tiêu cốt lõi của đề án này là đề xuất và triển khai một **Pipeline Tiền xử lý Dữ liệu Toàn diện** nhằm chuẩn hóa triệt để ngữ liệu thô, khắc phục hiện tượng Out-Of-Vocabulary (OOV), qua đó tối ưu hóa hiệu năng và vượt qua baseline của bài báo gốc.

Cấu trúc nhãn của bộ dữ liệu ViHSD:

- **Nhãn 0 (CLEAN):** Bình luận sạch, không chứa yếu tố độc hại hoặc xúc phạm.
- **Nhãn 1 (OFFENSIVE):** Bình luận mang tính xúc phạm, thô tục, chửi thề bộc phát nhưng không nhắm vào đối tượng cụ thể hay mang ý chí thù địch sâu sắc.
- **Nhãn 2 (HATE):** Ngôn từ thù địch độc hại nghiêm trọng, tấn công trực diện vào các nhóm người yếu thế, tôn giáo, chủng tộc hoặc tổ chức xã hội.

2. Bản Đồ Án Xạ: Kỹ Thuật Gốc vs. Điểm Mới Đột Phá

Dưới đây là bảng tổng hợp so sánh luồng xử lý cơ bản từ bài báo khoa học gốc và các giải pháp cải tiến mới được tích hợp vào hệ thống hiện tại:

Kỹ thuật / Giai đoạn	Giải pháp Nguyên bản (Bài báo gốc)	Điểm mới Tối ưu hóa (Đề án Đề xuất)
Xử lý Emoji	Loại bỏ hoàn toàn như nhiều kỹ thuật.	Bảo toàn và Dịch thuật: Chuyển đổi Emoji thành các token chữ (dạng English alias thông qua <code>emoji.demojize</code>) nhằm giữ lại đặc trưng phân cực cảm xúc (Polarity Features).
Xử lý Teencode & Từ lóng	Bỏ qua, giữ nguyên văn thô dẫn đến tokenizer phân rã sai ngữ nghĩa.	Lexicon-based Normalization: Áp dụng bộ từ điển ánh xạ từ lóng/viết tắt chuyên biệt đưa văn bản thô về tiếng Việt chính quy trước khi đưa vào mô hình.
Chuẩn hóa độ dài ký tự	Giữ nguyên (ví dụ: "giiiiii", "nguooo").	Lengthening Normalization: Sử dụng Regular Expression để cắt tĩa các ký tự lặp cảm xúc quá 3 lần về định dạng gốc chính xác.
Đồng nhất bảng mã	Không đề cập sâu hoặc xử lý không đồng nhất.	Unicode Normalization (NFC): Ép toàn bộ chuỗi ký tự về một chuẩn dựng sẵn để loại bỏ hiện tượng nổ kích thước từ điển do lỗi gõ dấu thanh tổ hợp.
Phân đoạn từ tiếng Việt	Sử dụng thư viện <code>pyvi</code> (gặp lỗi không tương thích với NumPy thế hệ mới).	Sử dụng thư viện hiện đại <code>underthesea</code> (với cơ chế kết nối từ ghép bằng dấu gạch dưới <code>format="text"</code>) giúp duy trì tính tương thích hệ thống cao.

3. Kiến Trúc Pipeline Tiền Xử Lý Phân Bước

Pipeline được cấu trúc thành một quy trình tuần tự khép kín, được kiểm soát chặt chẽ bằng cơ chế Logging để theo dõi trạng thái chuyển đổi của văn bản qua từng bước:

- Bước 1 (Unicode Normalization):** Chuyển chuỗi về dạng chuẩn NFC bằng thư viện `unicodedata`, đảm bảo tính ổn định tối đa trước khi thực hiện so khớp từ vựng.
- Bước 2 (Lowercasing):** Hạ toàn bộ văn bản về chữ thường nhằm giảm chiều không gian vector của các đặc trưng văn bản.

3. **Bước 3 (Noise Removal):** Sử dụng Regex xóa bỏ các liên kết URL (http/https/www), thẻ đề cập người dùng (`@mention`) và thẻ chủ đề (`#hashtag`).
4. **Bước 4 (Emoji Feature Extraction):** Chuyển hóa biểu tượng cảm xúc bộc phát (ví dụ: 😡) thành `:enraged_face:`). Bước này giữ vai trò cực kỳ quan trọng đối với mạng CNN và Transformer để bắt sắc thái tiêu cực.
5. **Bước 5 (Lengthening Cut):** Co ngắn các từ bị kéo dài ký tự phi quy chuẩn do bộc lộ cảm xúc cá nhân thái quá.
6. **Bước 6 (Lexicon Replacement):** Quét văn bản qua hệ thống từ điển Teencode và khôi phục ngữ nghĩa gốc của từ chữi thề hoặc từ viết tắt ẩn dụ mạng xã hội.
7. **Bước 7 (Word Segmentation & Stopwords):** Áp dụng `word_tokenize` và lọc bỏ các từ dừng rác ngữ pháp không mang trọng số phân loại.

4. Mã Nguồn Pipeline Tiền Xử Lý Dữ Liệu Hoàn Chỉnh (Python)

Dưới đây là toàn bộ mã nguồn của file `preprocessing.py` được thiết kế theo dạng hướng đường ống (pipeline) hoàn chỉnh, tương thích 100% với Python 3.11+, Pandas thế hệ mới, và tích hợp đầy đủ hệ thống ghi nhận log tiến trình trực quan:

```
import pandas as pd
import re
import unicodedata
from underthesea import word_tokenize
import emoji

# =====
# CẤU HÌNH HỆ THỐNG TỪ ĐIỂN VÀ THAM SỐ KHAI PHÁ DỮ LIỆU
# =====
# Bộ từ điển ánh xạ từ lóng, teencode và từ viết tắt phân cực mạnh
SLANG_DICT = {
    "dell": "đếch", "đéo": "đếch", "đm": "địt mẹ", "địt": "chửi thề",
    "cc": "cực cực", "lol": "lồn", "eo": "éo",
    "ko": "không", "k": "không", "khong": "không",
    "dc": "được", "đc": "được",
    "vs": "với", "3": "ba", "m": "mày", "t": "tao",
    "vkl": "vcl", "clmm": "địt mẹ", "cl": "cặc"
}

# Danh sách từ dừng cơ bản lọc nhiều cấu trúc văn bản
STOPWORDS = set(["và", "là", "như", "thì", "mà", "nếu", "có", "các", "những", "của"])

# =====
# CÁC HÀM TIỀN XỬ LÝ CHUYÊN SÂU THEO ĐỀ XUẤT ĐỒ ÁN
# =====
def unicode_normalization(text):
    """Đồng nhất bảng mã văn bản về chuẩn dạng sẵn Unicode NFC"""
    if not isinstance(text, str):
        return ""
    return unicodedata.normalize('NFC', text)

def remove_noise(text):
    """Lọc nhiễu kỹ thuật mạng xã hội: URLs, Mentions (@), Hashtags (#)"""
    text = re.sub(r'http\S+|www\S+|https\S+', '', text, flags=re.MULTILINE)
    text = re.sub(r'@\w+|\#\w+', '', text)
    return text

def extract_emoji_features(text):
    """Trích xuất đặc trưng phân cực Emoji thành chuỗi ký tự dạng văn bản"""
    return emoji.demojize(text)

def normalize_lengthened_words(text):
    """Chuẩn hóa các từ kéo dài ký tự bội lộ cảm xúc (ví dụ: giiiii -> gì)"""
    # Thay thế các cụm ký tự trùng lặp từ 3 lần trở lên thành 1 ký tự gốc
```



```

print(f"\n► ĐANG XỬ LÝ TẬP TRAIN ({len(df_train)} dòng)...")
df_train = run_pipeline(df_train, TEXT_COLUMN)

print(f"\n► ĐANG XỬ LÝ TẬP VALIDATION/DEV ({len(df_dev)} dòng)...")
df_dev = run_pipeline(df_dev, TEXT_COLUMN)

print(f"\n► ĐANG XỬ LÝ TẬP TEST ({len(df_test)} dòng)...")
df_test = run_pipeline(df_test, TEXT_COLUMN)

print("\n=== ĐANG LƯU KẾT QUẢ XUỐNG FILE PREPROCESSED ===")
# Chỉ trích xuất cột text sạch và cột nhãn mục tiêu để tối ưu kích thước lưu trữ
df_train[['clean_text', 'label_id']].to_csv('train_preprocessed.csv', index=False)
df_dev[['clean_text', 'label_id']].to_csv('dev_preprocessed.csv', index=False)
df_test[['clean_text', 'label_id']].to_csv('test_preprocessed.csv', index=False)

print("✅ TIỀN XỬ LÝ HOÀN TẤT THÀNH CÔNG! Dữ liệu đã sẵn sàng chuyển sang bước
nhúng.")

except KeyError as e:
    print(f"\n❌ LỖI CẤU TRÚC: Cột {e} không tồn tại trong dataset của bạn.")
except FileNotFoundError as e:
    print(f"\n❌ LỖI ĐƯỜNG DẪN: Không tìm thấy file CSV thô tại thư mục hiện hành. Chi
tiết: {e}")
except Exception as e:
    print(f"\n❌ LỖI HỆ THỐNG: Quá trình thực thi crash tại: {e}")

if __name__ == "__main__":
    process_dataset()

```

5. Kế hoạch Hoàn thiện Đồ án & Các Bước Tiếp Theo

Sau khi thực thi file mã nguồn trên để tạo ra các tập dữ liệu sạch (`train_preprocessed.csv`, `dev_preprocessed.csv`, `test_preprocessed.csv`), đồ án cần tiếp tục triển khai các pha sau để cấu thành một báo cáo khoa học hoàn chỉnh:

Bước 1: Trích chọn Đặc trưng & Nhúng từ (Feature & Embedding Extraction)

Bản chất văn bản dạng chuỗi ký tự sau xử lý cần được chuyển đổi sang phân bố không gian ma trận số:

- **Kiến trúc mạng truyền thống (CNN, GRU):** Sử dụng kỹ thuật TF-IDF biểu diễn tần suất phân bố, hoặc sử dụng WordEmbedding (như Word2Vec hoặc FastText tiếng Việt được pre-trained trên kho ngữ liệu lớn) để ánh xạ các token sạch sang không gian vector 300 chiều.
- **Kiến trúc Transformer (m-BERT, XLM-RoBERTa):** Nạp trực tiếp chuỗi `clean_text` vào bộ Tokenizer của Hugging Face (ví dụ: `BertTokenizerFast`). Bộ Tokenizer sẽ tự động chuyển hóa các ký tự Emoji đã dịch (như `:enraged_face:`) và từ ngữ chính quy hóa thành các ID token tương ứng.

Bước 2: Huấn luyện Thử nghiệm Đa Mô hình (Model Training Cross-Validation)

Nhóm nghiên cứu tiến hành thiết lập thực nghiệm tối thiểu 04 phương pháp học máy (vượt yêu cầu đề cương đồ án) để so sánh đối chứng hiệu quả:

1. **Text-CNN:** Sử dụng các bộ lọc tích chập có kích thước cửa sổ khác nhau ($K=3, 4, 5$) để trích xuất n-gram đặc trưng cục bộ cực kỳ mạnh mẽ, chuyên trị việc bắt các từ xúc phạm nằm rải rác bất biến vị trí trong bình luận mạng xã hội.
2. **BiGRU (Bidirectional Gated Recurrent Unit):** Kiến trúc mạng hồi quy hai chiều tích hợp cổng quên giúp nắm bắt sự phụ thuộc ngữ cảnh chuỗi văn bản dài theo cả hai chiều quá khứ và tương lai, rất nhạy bén với nhãn mang cấu trúc ẩn dụ phức tạp (Nhãn 2 - HATE).
3. **m-BERT Cased (Baseline):** Fine-tune lại mô hình BERT đa ngôn ngữ để đối chứng trực tiếp với kết quả 62.69% của bài báo khoa học gốc.
4. **XLM-RoBERTa / PhoBERT:** Thử nghiệm mở rộng trên mô hình Transformer chuyên sâu tiếng Việt thế hệ mới để đẩy chỉ số F1-macro lên ngưỡng tối đa.

Bước 3: Đánh giá & Phân tích lỗi (Evaluation & Error Analysis)

Do tập dữ liệu **ViHSD** có sự mất cân bằng nghiêm trọng giữa số lượng bình luận nhãn CLEAN (chiếm đa số tuyệt đối) và nhãn HATE/OFFENSIVE, chỉ số `Accuracy` thông thường sẽ bị lệch và không phản ánh đúng năng lực mô hình. Nhóm bắt buộc phải tập trung chứng minh tính đúng đắn qua độ đo **F1-Macro**.

Kế hoạch lập Ma trận nhầm lẫn (Confusion Matrix): Xuất biểu đồ nhiệt (Heatmap Confusion Matrix) để chỉ rõ: Nhờ việc tích hợp bước khôi phục teencode và dịch thuật Emoji, tỷ lệ mô hình dự đoán sai từ nhãn 1, nhãn 2 về nhãn 0 (tỷ lệ False Negative ở các lớp xúc phạm) đã sụt giảm rõ rệt so với các cấu trúc thử nghiệm thô ban đầu.

Báo cáo Kỹ thuật Đồ án Khai phá Dữ liệu Mạng Xã hội - Đại học Công nghệ Thông tin - 2026